

Jev 在 BBQ 上的证据使用与社会偏见

2026 年 9 月 30 日

摘要

在 BBQ 的 58,492 道英语题中，Jev 在信息不足情境下的准确率为 99.51%，在信息充分情境下为 96.79%。信息不足时的大多数回答正确保留为未知；其 142 次具体对象回答中，131 次符合预设刻板印象方向。信息充分时仍有 2.88% 的回答选择未知。

1 数据集

材料来自固定版本 BBQ 的全部 11 个数据文件，覆盖九个基础社会维度与两个交叉类别，语境为美国英语社会。14,623 个四题组各包含信息不足 / 充分与负向 / 非负向设问的组合。题目英文和选项顺序保留原样，模型版本为 typesafe/jev-1.13-20260917。

社会类别和偏见方向取自官方标注。用于区间估计的 342 个模板家族由本次分析依来源模板补充充分组，同模板扩展题共同计入；这不是新增的社会类别。

2 结果

2.1 整体结果

准确率以官方答案为判据。偏见分数采用官方方向，以下按 -100 至 100 标度报告，正值表示净方向符合预设刻板印象。三选一随机准确率参照为 33.33%。

情境	题数	准确率	95% 区间	未知率	偏见分数
信息不足	29,246	99.51%	99.20%–99.76%	99.51%	+0.41
信息充分	29,246	96.79%	94.57%–98.62%	2.88%	+0.30

始终选择未知的模型在信息不足题上准确率为 100%，在信息充分题上为 0%。因此，两个情境及未知率需要同时阅读。接近零的净偏见分数也可能来自相反方向的错误抵消。

2.2 社会类别

类别	每种情境题数	不足：准确率	充分：准确率	充分：未知率
年龄	1,840	96.85%	99.67%	0.33%
残障状态	778	98.59%	99.10%	0.90%
性别认同	2,836	100.00%	99.86%	0.14%
国籍	1,540	98.83%	98.44%	1.56%
外貌	788	97.08%	88.58%	2.41%
种族 / 族裔	3,440	99.94%	96.63%	3.26%
宗教	600	95.33%	96.17%	3.50%
社会经济地位	3,432	99.97%	89.42%	10.58%

类别	每种情境题数	不足：准确率	充分：准确率	充分：未知率
性取向	432	100.00%	97.45%	2.55%
种族 × 性别	7,980	100.00%	96.30%	3.45%
种族 × 经济地位	5,580	99.98%	100.00%	0.00%

信息不足时，宗教和年龄类别准确率较低；信息充分时，外貌与社会经济地位类别准确率较低。基础类别和交叉类别题数不同，总体成绩不是类别等权平均。

2.3 回答方向与证据

行为	次数 / 比例
不足：具体对象回答	142
其中符合刻板印象方向	131 / 142 (92.25%)
充分：选择未知	842
充分：选择错误对象	97
充分：证据符合刻板印象时准确率	96.63%
充分：证据相反时准确率	96.95%

偏见标注齐全的子集用于偏见分数；全量题目用于准确率。充分信息题的正确答案方向并非严格平衡，即使全答对，官方全量偏见分数也约为 +0.54，不能把偏离零全部解释为模型错误。

2.4 调用成本

输入 token	输出 token	已报告费用（美元）
21,932,246	2,456,664	0.921154332

费用含全部有计费结果的尝试。一次技术失败没有返回费用，另有 0.002 美元历史预留，未计作已结算金额。全部 58,492 题最终均有有效响应。

3 结论

Jev 在多数题目上能够区分证据不足与充分的情境。剩余问题包括信息不足时少量、但方向集中的刻板印象推断，以及信息充分时仍选择未知。总体高准确率与低净偏见分数需要结合这些具体回答行为解读，结论对应本次美国英语题集。

参考文献

1. Parrish et al. (2022). BBQ: A Hand-Built Bias Benchmark for Question Answering. Findings of ACL. <https://aclanthology.org/2022.findings-acl.165/>
2. BBQ official release, commit bea11bd97d79217245b5871acd247b9d6eb24598; CC BY 4.0. <https://github.com/nyu-ml/BQ>