

Jev 在 MoCa 因果与道德判断中的人类一致性

2026 年 9 月 30 日

摘要

在 MoCa 的 206 个英语故事上，Jev 与每题 25 人聚合判断的三类一致率为 43.69%。因果题为 39.58%，道德题为 53.23%。Jev 能区分人类明确肯定与否定的题目，但对人类分歧较大的因果故事较少落入模糊区间。

1 数据集

材料包括 144 个因果故事与 62 个道德许可故事。参照为数据集每题的 25 个人类二元判断。三类为 Yes、No 和 Ambiguous，沿用 0.4 / 0.6 边界；Jev 的第三类由二选一概率派生。模型版本为 typesafe/jev-1.13-20260917。因素名称沿用来源中的专家标注，同一故事可以包含多个因素。人类比例与 Jev 结构化选择概率具有不同含义，本文报告它们在这组故事上的一致性与数值差异。

2 结果

2.1 整体结果

以数据集的人类聚合标签为一致性判据，不将人类多数判断称为道德正确答案。三类均匀随机参照为 33.33%，总体多数类参照为 36.41%。AUROC 只使用人类非模糊题。

范围	题数	一致率	95% 区间	AUROC	概率 MAE
全部	206	43.69%	36.89%–50.49%	0.704	0.308
因果	144	39.58%	31.94%–47.92%	0.748	0.333
道德	62	53.23%	40.32%–66.13%	0.852	0.249

2.2 判断分布

范围	来源	Yes	No	Ambiguous
因果	人类	48	50	46
因果	Jev	98	35	11
道德	人类	23	10	29
道德	Jev	22	21	19

46 个被人类归为模糊的因果题中，Jev 只有 1 题同样归为模糊；道德题相应为 12/29。因果题中 Jev 的肯定判断明显更多，说明三类一致率较低主要涉及判断分布及边界差异。

2.3 因素分组的平均差异

分组变化	两组题数	人类差值	Jev 差值
行动 → 不作为	80 / 32	+0.028	-0.179
知情 → 不知情	23 / 20	-0.009	+0.195
合取 → 析取	66 / 32	-0.030	-0.250
异常 → 正常	44 / 45	-0.228	-0.294
他人受益 → 自己受益	26 / 22	+0.101	-0.015
意外 → 工具性	18 / 30	-0.118	-0.067
可避免 → 不可避免	22 / 26	+0.131	+0.136
非个人施力 → 个人施力	24 / 24	-0.058	-0.067

差值描述后一组相对前一组的平均肯定比例 / 概率变化。因素相互重叠，故事内容也随组变化，因此这些结果为描述性关联，不是单个因素的独立因果效应。

2.4 调用成本

输入 token	输出 token	已报告费用 (美元)
109,940	6,798	0.00461748

206 次请求全部一次成功，没有未知费用或重试。

3 结论

Jev 与人类聚合判断呈现部分相似性，道德题的一致性高于因果题。对人类明确肯定与否定的区分能力，并未转化为对人类模糊判断的同等识别。因素分组的部分平均方向相同，另一些方向不同；这些结果描述相同故事上的判断关系。

参考文献

1. Nie et al. (2023). MoCa: Measuring Human-Language Model Alignment on Causal and Moral Judgment Tasks. NeurIPS. <https://arxiv.org/abs/2310.19677>
2. MoCa official repository, commit 1b61a20294247480d64675ceb19751ef4e1e878f. <https://github.com/cicl-stanford/moca>