

Jev 在 MoralChoice 中的道德选择与稳定性

2026 年 9 月 30 日

摘要

在 MoralChoice 的 1,367 个英语情境中，每个情境包含六个结构化判断。687 个低歧义情境的六种变体全部选择参考行动。680 个高歧义情境中，69.07% 的判断选择 action1，90.59% 的情境在六种变体下选择同一行动。高歧义情境的选择通常稳定，但对提问形式和顺序仍有敏感性。

1 数据集

发布数据包含 687 个低歧义和 680 个高歧义情境。低歧义情境以 action1 为参考行动，高歧义情境不设统一正确答案。每个情境包括 ab、repeat、compare 三种形式及各自的正逆序，共 8,202 个判断。模型版本为 typesafe/jev-1.13-20260917。

形式和顺序沿用原研究设计，输出改为 Jev 的结构化二选一。同一情境六个问题在一次请求中回答；repeat 不再测试逐字文本复述。顺序及跨形式稳定性为本次适配的分析指标，六个判断不作为六个独立情境。

2 结果

2.1 整体结果

低歧义以发布数据的参考行动为判据，随机二选一参照为 50%。高歧义仅描述选择分布，不计算正确率。

指标	低歧义	高歧义
情境数	687	680
判断数	4122	4080
action1 选择比例	100.00%	69.07%
六种变体选择同一行动	100.00%	90.59%
平均 P(action1)	99.82%	67.11%

低歧义的情境级全部选择参考行动比例为 100%，Wilson 95% 区间为 99.44%–100%。高歧义的 action1 比例受发布数据中行动内容的排列影响，不等于首位选项偏好。

2.2 高歧义稳定性

形式	正逆序一致	一致率	平均概率变化	首位选择率
ab	661 / 680	97.21%	3.15%	49.04%
repeat	658 / 680	96.76%	3.25%	48.97%
compare	643 / 680	94.56%	6.36%	47.57%

616/680 个情境的六种变体选择相同。compare 的正逆序一致率最低，表明是 / 否比较形式更容易随顺序改变底层选择。六种概率的情境内平均极差为 10.75 个百分点。

2.3 辅助规则分组

辅助规则标签来自发布数据，并可能相互重叠。仅比较一个行动被标为违反、另一个明确标为不违反该规则的情境。完整聚合表保存在机器可读汇总中。

规则标签	高歧义情境数	选择不违反该规则	六种变体均不违反
break_law	195	84.02%	76.92%
break_promise	108	68.21%	65.74%
cheat	138	93.24%	91.30%
death	84	64.88%	59.52%
deceive	262	86.39%	82.44%
disable	144	67.13%	61.11%
duty	409	86.15%	81.66%
freedom	219	54.26%	48.86%
pain	356	57.12%	51.97%
pleasure	276	50.60%	45.65%

2.4 调用成本

输入 token	输出 token	已报告费用 (美元)
1,098,374	250,161	0.046131708

1,367 次请求全部成功，无重试或未知费用。

3 结论

Jev 在低歧义情境下与参考选择完全一致。高歧义情境没有统一正确答案，约九成情境的底层行动在六种形式和顺序组合中保持一致；其余变化主要集中在比较形式。此结果描述结构化选择及其稳定性，不将集中的选择概率解释为道德正确性或人类意见比例。

参考文献

1. Scherrer et al. (2023). Evaluating the Moral Beliefs Encoded in LLMs. NeurIPS. https://proceedings.neurips.cc/paper_files/paper/2023/file/a2cf225ba392627529efef14dc857e22-Paper-Conference.pdf
2. MoralChoice data release, commit 89c0fe7b158b5ade5d10e0644c1aa20ab4c78cbe; CC BY 4.0. <https://huggingface.co/datasets/ninoscherrer/moralchoice>