

Jev 在 SocialIQA 社会常识选择题上的表现

2026 年 9 月 30 日

摘要

在 SocialIQA v1.4 的 2,224 道英语测试题中，Jev 答对 1,792 道，准确率为 80.58%，按重复题目聚类的 95% 区间为 78.81%–82.21%。九个官方来源分组的准确率为 78.11%–84.66%。结果反映对日常人物动机、情绪和行动后果的选择判断表现。

1 数据集

材料为作者发布的 v1.4 test 全部 2,224 行，每题包含英语情境、问题及三个选项。每题独立作答，按公开参考标签评分。模型版本为 typesafe/jev-1.13-20260917。

九个分组使用官方 promptDim 字段。该字段记录 ATOMIC 问题生成来源，人工改写后的问题可能偏离原始维度，因此分组不作为九种独立心理能力的测量。材料为长期公开的英语选择题；本次成绩描述这一题集上的表现。

2 结果

2.1 整体结果

以数据集提供的答案为判据。全部正式题均获得有效响应，随机三选一参照为 33.33%。

指标	结果
正式题数	2,224
答对题数	1,792
准确率	80.58%
题目聚类 95% 区间	78.81%–82.21%
不同完整题目数	2203
不同完整题目准确率	80.57%

2.2 官方来源分组

分组	题数	答对	准确率
oEffect (对他人的影响)	159	127	79.87%
oReact (他人情绪反应)	223	179	80.27%
oWant (他人后续意愿)	252	201	79.76%
xAttr (主角属性)	297	232	78.11%
xEffect (对主角的影响)	103	82	79.61%
xIntent (主角动机)	297	239	80.47%
xNeed (主角事前需要)	277	225	81.23%
xReact (主角情绪反应)	277	220	79.42%
xWant (主角后续意愿)	339	287	84.66%

xWant 分组最高，xAttr 分组最低。各组题量不同，排序仅描述本题集，不构成稳定能力等级。

2.3 调用成本

输入 token	输出 token	已报告费用 (美元)
851,327	84,512	0.035755734

正式评测已报告费用为 0.035755734 美元。另有 12 道接口调试题；含调试的已报告总费用为 0.035949816 美元，共 855,948 输入 token、84,968 输出 token。一次技术失败未报告费用，历史账本另保留 0.01 美元预留；预留不计作已结算费用。

3 结论

Jev 在这份英语社会常识题集上达到 80.58% 准确率，能够对多数人物动机、情绪和行动后果作出符合参考答案的选择。仍有 432 题未选中参考答案。该表现可作为社会情境理解的基线，分数的解释限于本次选择题条件，不等同于情感体验或助人意愿。

参考文献

1. Sap et al. (2019). Social IQa: Commonsense Reasoning about Social Interactions. EMNLP-IJCNLP. <https://aclanthology.org/D19-1454/>
2. SocialIQa v1.4: authors' dataset release, CC BY 4.0. <https://maartensap.com/social-iqa/>